The background of the slide is a painting. On the left, a woman in a light-colored dress and a wide-brimmed hat sits on a wooden bench, holding a small child. On the right, another woman in a dark blue long-sleeved top and a long brown skirt stands with her back to the viewer, looking at a bush of red and white flowers. She is holding a woven basket. The scene is set in a garden with a large tree on the left and a building with a thatched roof on the right.

反问题笔记

Inverse Problem Notes

讲学笔记

RESEARCH NOTE, AT UNIVERSITY OF HOUSTON

[GITHUB.COM/CAINMAGI/RESEARCH-NOTEBOOKS](https://github.com/caimagi/research-notebooks)


This is the personal note of learning inverse problem theory, written by *Yuchen Jin*. Anyone who read this book could share it freely, but any activities of recompilation, modification or reproduction are not permitted, according to the authority of the editor.

First release, February 13, 2018



目 录

1	普适离散反问题	5
1.1	模型空间与数据空间	5
1.1.1	模型空间	6
1.1.2	数据空间	7
1.1.3	合并流形	7
1.2	信息态	7
1.2.1	概率的定义	7
1.2.2	概率的解释	9
1.2.3	概率的性质	9



1. 普适离散反问题

反问题 (*inverse problem*) 与正问题 (*forward problem*, *modelization problem*, *simulation problem*) 相对, 是基于已经存在的观测结果, 逆推出产生如此观测结果的模型。一个最大的不同是, 正问题里确定模型时, 观测结果有唯一解; 反问题里确定观测结果时, 模型没有唯一解。

故而, 为了得到有效的解、或解集 (*collection of models*), 往往须要对问题施加约束条件, 这种约束条件可以看成是对模型的一种先验信息, 它定义了解集可能存在的概率分布 (因而我们可以探索到最大概率的解)。

当数据有较高的采样频率时, 可以描述一个离散反问题 (*discrete inverse problem*) 来代替原问题。离散反问题从数学上更容易解, 但它不能完全等同于原问题, 因为离散化的过程中引入了一些简化, 造成一些信息因为离散化被隐藏了起来。

本章的核心是参数集 (*parameter set*) 上的“状态信息 (*state of information*)”, 一般被描述为前述的先验信息/概率密度。这种方法可以用在完全非线性问题里, 但计算开销甚大。且它的解一般少于传统方法得到的解。

1.1 模型空间与数据空间

研究一个物理系统 \mathcal{G} 一般分为三步:

- (1) **系统参数化** (*parameterization of system*): 确定一个最小的参数集, 使得通过这些参数可以完全描述物理系统;
- (2) **正向模型** (*forward modeling*): 预测并给定一些参数, 通过物理定律, 建立参数 \rightarrow 观测结果之间的关系;
- (3) **反向模型** (*inverse modeling*): 使用这些预测的参数, 推测出实际模型参数的解。

可见, 前两步是归纳 (*inductive*), 最后一步是演绎 (*deductive*), 前两步的物理建模可能更困难; 至于最后一步, 有成熟、有效的数学方法来解。

首先让我们考量系统参数化的问题:

■ 例 1.1 考虑一个弹性系统 \mathcal{G} , 对于空间上任意的点 \mathbf{x} , 有压力 $\sigma^{ij}(\mathbf{x})$, 拉力 $\varepsilon^{ij}(\mathbf{x})$, 则可以定义弹性硬度张量 $c_{kl}^{ij}(\mathbf{x})$ 为:

$$\sigma^{ij}(\mathbf{x}) = c_{kl}^{ij}(\mathbf{x}) \varepsilon^{kl}(\mathbf{x}). \quad (1.1)$$

同时还可以定义弹性柔度张量 $s_{kl}^{ij}(\mathbf{x})$ 为:

$$\varepsilon^{ij}(\mathbf{x}) = s_{kl}^{ij}(\mathbf{x}) \sigma^{kl}(\mathbf{x}). \quad (1.2)$$

这里, 张量 \mathbf{s} 是张量 \mathbf{c} 的逆, 亦即 $c_{kl}^{ij} s_{mn}^{kl} = \delta_m^i \delta_n^j$ 。故而选择这两个参数中的任何一个都是**完全等价** (*completely equivalent*) 的。 ■

选择任意一组符合上述要求的特定参数集就是**系统参数化**, 对于两个等价的参数集, 其参数之间可以一一映射。

1.1.1 模型空间

与系统参数化无关, 我们可以引入一个**抽象空间**, 或称为**流形** (*manifold*), 用其中的每一个**点**代表一个模型 \mathbf{m} , 于是这样的流形记为**模型空间** (*model space*) $\mathfrak{M} = \{\mathbf{m}_1, \mathbf{m}_2, \dots\}$ 。

一个**模型空间**可以被不同的 (等价) 系统参数描述。例如, 设若 \mathfrak{M} 的参数有两维, 记为 $\{m^1, m^2\}$, 则 m^1 和 m^2 可以选用不同的参数进行测量。由此定义的**模型**, 或记为**点** \mathbf{m} , 一般来说不可以看成是一个 (线性空间内的) 向量, 因为其坐标轴可能是非线性的。即使坐标轴都是线性的, 也一般不是笛卡尔坐标系。

■ **例 1.2** 考虑一个**模型空间** \mathfrak{M} 已经确定了系统参数为 $\{\kappa, \mu\}$ (分别为体积模量和剪切模量), 可以定义两个模型 $\mathbf{m}_1, \mathbf{m}_2$ 之间的距离为

$$d = \sqrt{\left(\log \frac{\kappa_2}{\kappa_1}\right)^2 + \left(\log \frac{\mu_2}{\mu_1}\right)^2}. \quad (1.3)$$

若以对数化的系统参数 $\{\kappa^* = \log \kappa, \mu^* = \log \mu\}$ 来代替(1.3)的参数, 有:

$$d = \sqrt{(\kappa_2^* - \kappa_1^*)^2 + (\mu_2^* - \mu_1^*)^2}. \quad (1.4)$$

可见, (1.4) 是的参数是笛卡尔坐标系, 但(1.3)的不是。 ■

性质 1.1.1 – 离散性. 须知的是, 一个实际物理模型, 其**参数系** (*set of quantities*) (亦即坐标轴) 往往是连续的, 记为 $m(\mathbf{x})$; 但本章考虑的模型是经过抽样、离散化的模型, 其**参数系**为 $m^\alpha = m^\alpha(\mathbf{x})$ 。坐标轴的离散性满足以下条件:

- (1) 参数系由选取的系统参数决定, 一个模型可以选用不同的参数系;
- (2) 参数系维数 α 有限, 本章不考虑无限的情况;
- (3) 参数系的抽样应该足够多, 能不失真地反映出原始模型的特征;
- (4) 参数系的值本身可以取连续也可以取离散, 为了方便表达, 可以默认认为取值总是连续的, 因为离散的取值可以用**狄拉克** (*Dirac*) 函数表达。 ■

性质 1.1.2 – 线性. 设任意两个同属一个模型空间 \mathfrak{M} , 使用同一系统参数 m^α 的模型 $\mathbf{m}_1, \mathbf{m}_2$, 其任意第 i 维的值均满足:

$$(\mathbf{m}_1 + \mathbf{m}_2)^\alpha = (\mathbf{m}_1)^\alpha + (\mathbf{m}_2)^\alpha, \quad (1.5)$$

$$(\lambda \mathbf{m})^\alpha = \lambda (\mathbf{m})^\alpha. \quad (1.6)$$

这样的 \mathfrak{M} 称为**线性模型空间** (*linear model space*), 记为 \mathbb{M}

例 1.2使用的对数化系统参数 $\{\kappa^*, \mu^*\}$ 是可以构成一个**线性模型空间**。因此, 此例中的距离 d 相当于该线性空间的**Euclidean 范数**。

为了处理一个反问题, 设模型空间 \mathfrak{M} 为全集, 其任意一个子集记为 \mathcal{A} , 则可以令全集概率 $P(\mathfrak{M}) = 1$, 且其子集概率 $P(\mathcal{A}) \in [0, 1]$ 。此处定义的概率, 是通过一种特定的关联关系定义的, 这种关系不受到空间是否是线性的影响。并且, 能相应地根据该概率求出每个模型的概率密度分布。

1.1.2 数据空间

对于一个模型的观测结果, 由于观测仪器的不同也可能产生诸多不同的结果, 设全集 \mathfrak{D} 为所有可观测仪器产生的观测结果的集合, 那么任何一组来自一个仪器的测量结果都可以看成它的元素 \mathbf{d} ; 与 \mathfrak{M} 相似, \mathfrak{D} 同样也可以看成是一个**流形**, \mathbf{d} 可以看成是流形中的一个**点**。

与性质 1.1.1和性质 1.1.2相似, 我们讨论的数据空间也有类似的性质。离散性此处从略, 在此我们介绍线性:

性质 1.1.3 – 线性. 在一个线性数据空间 \mathbb{D} 内, 任意两组测量结果 (来自两个仪器) $\mathbf{d}_1, \mathbf{d}_2$, 其任意第 i 维的值均满足:

$$(\mathbf{d}_1 + \mathbf{d}_2)^\alpha = (\mathbf{d}_1)^\alpha + (\mathbf{d}_2)^\alpha, \quad (1.7)$$

$$(\lambda \mathbf{d})^\alpha = \lambda (\mathbf{d})^\alpha. \quad (1.8)$$

1.1.3 合并流形

有时候, 一个物理系统的输入和输出参数可以清楚地分开, 这时使用两个**流形** $\mathfrak{M}, \mathfrak{D}$ 来描述并无问题。但某些情况下 (例如有反馈系统), 不能做到这一点。因此有时我们也用一个合并的**流形** \mathfrak{X} 来表示整个**参数空间** (*parameter space*)。这种情况下, 其元素 (或点) \mathbf{x} 被称为一组参数。

1.2 信息态

本节讨论了基于**概率论**定义的信息态 (*states of information*)。

1.2.1 概率的定义

考虑一个有限维流形 \mathfrak{X} , 正如在节 1.1.1末尾提到的那样, 可以从中定义任意的子集 $\mathcal{A}, \mathcal{B}, \dots$, 我们称 $\mathfrak{X}, \mathcal{A}, \mathcal{B}, \dots, \emptyset$ 所属的为一个域 F , 且 F 是一个 **σ 域** (*σ Field*)。

定义 1.2.1 – σ 域. 由集合 Ω 的众子集 (例如 $\mathcal{A}, \mathcal{B}, \dots$) 构成的超集 (*super set*), 在满足以下条件时称为一个域 (*Field*)。

- (1) $\Omega \in F$;
- (2) 若 $\mathcal{A} \in F$, 则 $\bar{\mathcal{A}} \in F$;
- (3) 若 $\mathcal{A}, \mathcal{B} \in F$, 则 $\mathcal{A} \cup \mathcal{B} \in F$ 。

特别地, 如果 F 内所有满足两两互斥的集合 $\mathcal{A}_i, i = 1 \rightarrow \infty$, 其交集 \mathcal{A} 满足

$$\mathcal{A} = \bigcup_{i=1}^{\infty} \mathcal{A}_i, \quad \mathcal{A} \in F, \quad (1.9)$$

则这样的域 F 称为 σ 域。

由于满足 σ 域, 若对每个子集关联到一个概率算子 $P(\cdot)$, 则该算子满足性质 1.2.1。

性质 1.2.1 – 概率算子的基本性质.

- (1) 互斥的集合 \mathcal{A}, \mathcal{B} 满足: $P(\mathcal{A} \cup \mathcal{B}) = P(\mathcal{A}) + P(\mathcal{B})$;
- (2) 趋向空集 \emptyset 的集合序列 $\mathcal{A}_1 \supseteq \mathcal{A}_2 \supseteq \dots$ 对应地满足 $\lim_{i \rightarrow \infty} P(\mathcal{A}_i) = 0$;
- (3) 空集 \emptyset 满足 $P(\emptyset) = 0$;
- (4) 任意的两集合并集的概率: $P(\mathcal{A} \cup \mathcal{B}) = P(\mathcal{A}) + P(\mathcal{B}) - P(\mathcal{A} \cap \mathcal{B})$.

于是, 考量模型 $\mathbf{x} \in \mathfrak{X}$ (同时也是一组参量), 则可以定义

定义 1.2.2 – 模型集的概率. 定义一个多维参量的实函数 $f(\mathbf{x})$, 则集合 \mathcal{A} 的概率定义为:

$$P(\mathcal{A}) = \int_{\mathbf{x} \in \mathcal{A}} f(\mathbf{x}) d\mathbf{x}. \quad (1.10)$$

若 $\forall \mathbf{x}, f(\mathbf{x}) > 0$ 且 $P(\mathfrak{X}) = 1$, 这样的实函数 f 称为概率密度函数, P 称为概率或对**标准化测度** (*normalized measurement*) 的概率。

若以上条件不满足, 这样的实函数称为**相对概率密度函数** (*relative probability density function*), P 称为**相对概率**或对**非标准化测度** (*nonnormalized measurement*) 的概率。

例如, 对定义域 $\{x > 0\}$ 的单变量实区间定义 $f = 1/x$, 显然该函数对全集的积分 P 为 ∞ , 故其不能代表概率, 但可以用来比较两个区间 \mathcal{A}, \mathcal{B} 上对应的积分 P , 这就是其称为**相对概率**的原因。

由于模型 \mathbf{x} 往往有实际的物理意义 (例如每个变量都代表一个物理量, 具有一个特定的物理量纲 (*physical dimensions*)), 由于 P 无量纲, 通常 f 需要是一个有量纲的函数, 并且其量纲可以抵消模型 \mathbf{x} 的量纲。

若对模型 \mathbf{x} 能进行一个坐标变换, 使得新坐标系下的模型 $\mathbf{x}^* = \mathbf{x}^*(\mathbf{x})$, 于是有

$$P(\mathcal{A}) = \int_{\mathbf{x} \in \mathcal{A}} f(\mathbf{x}) d\mathbf{x} = \int_{\mathbf{x}^* \in \mathcal{A}} f^*(\mathbf{x}^*) d\mathbf{x}^* = \int_{\mathbf{x}^* \in \mathcal{A}} f(\mathbf{x}) \left| \frac{\partial \mathbf{x}}{\partial \mathbf{x}^*} \right| d\mathbf{x}^*. \quad (1.11)$$

1.2.2 概率的解释

1.2.3 概率的性质